

Classificação do Desempenho das Empresas Comerciais Brasileiras nos Cenários de Pré-Pandemia, Pandemia e Retomada (2017–2023)

Relatório do Projeto — Sprint 1

Base de dados, análise exploratória e descritiva

Equipe

- Nicolas Simões Leão Santos
- Gisele Costa Siqueira
- Silvio Bruno do Nascimento Lima
- Marcos Vinicius Herbster
- Luiz Eduardo Alves

Fortaleza, setembro de 2026

Sumário

1. Introdução	3
2. Base de dados selecionada	3
2.1 Descrição geral	3
2.2 Atributos	4
3. Preparação e verificação dos dados	4
3.1 Carregamento e reestruturação	4
3.2 Recorte geográfico	5
3.3 Verificação de qualidade e cobertura	5
4. Análise exploratória e descritiva	5
4.1 Estatísticas descritivas	6
4.2 Distribuição dos indicadores	6
4.3 Variação anual por período (boxplots)	7
4.4 Evolução temporal por macrorregião	8
4.5 Correlação entre os indicadores	8
4.6 Pessoal ocupado × receita bruta	9
4.7 Comparação por grupo de atividade	10
4.8 Ranking: UFs mais afetadas em 2020 e com maior recuperação em 2023	10
5. Síntese dos achados e próximos passos	11
5.1 Principais achados da Sprint 1	11
5.2 Próximos passos (Sprint 2 — pré-processamento)	11
6. Gestão do projeto	12
6.1 Quadro Kanban (Trello)	12
6.2 Registro das atividades (16 a 30 de setembro de 2026)	12
7. Seções reservadas para as próximas sprints	12
7.1 Pré-processamento dos dados (Sprint 2)	12
7.2 Modelagem (Sprint 3)	12
7.3 Avaliação e resultados (Sprint 4)	12
7.4 Conclusão	12
Referências	13

1. Introdução

Este documento é a primeira versão do relatório do projeto de ciência de dados sobre o desempenho das empresas comerciais brasileiras nos cenários de pré-pandemia (2017–2019), pandemia (2020–2022) e retomada (2023). O objetivo final do projeto é construir um modelo de **classificação supervisionada** capaz de classificar o desempenho das empresas comerciais em classes (queda / estável / crescimento) em cada cenário, a partir de indicadores oficiais da Pesquisa Anual de Comércio (PAC) do IBGE.

Conforme o roteiro da disciplina, esta versão cobre apenas as seções previstas para a **Sprint 1**: a escolha e descrição da base de dados (Passo 1) e a análise exploratória e descritiva, com os gráficos produzidos e suas respectivas interpretações (Passo 2). As seções referentes ao pré-processamento, à modelagem e à avaliação dos resultados estão reservadas para as próximas sprints e aparecem ao final do documento apenas como marcadores.

Todo o código da análise está no notebook **Sprint1.ipynb**, publicado no repositório do projeto no GitHub (<https://github.com/NicolasSimoes/cienciasdedados>). As figuras e os números deste relatório foram gerados diretamente por esse notebook.

Entregas da Sprint 1 e onde estão neste documento:

Entrega	Onde está
1. A base de dados selecionada	Seção 2
2. A análise exploratória e descritiva (código no GitHub)	Seções 3 e 4; notebook Sprint1.ipynb
3. Gráficos e visualizações com interpretações	Seção 4 (Figuras 1 a 6 e Tabelas 5 e 6)
4. Quadro Kanban no Trello	Seção 6.1
5/6. Primeira versão do documento (só as seções da Sprint 1)	Este documento; seções futuras reservadas (Seção 7)
7. Registro das atividades de 16 a 30/09/2026	Seção 6.2

2. Base de dados selecionada

2.1 Descrição geral

Item	Descrição
Base escolhida	Tabela 1407 — Dados gerais das empresas comerciais por grandes regiões e unidades da federação de atuação das empresas e divisão de comércio e grupo de atividade. Base real, pública e oficial.
Origem	IBGE — Pesquisa Anual de Comércio (PAC), obtida no SIDRA: https://sidra.ibge.gov.br/Tabela/1407
Contexto	A PAC acompanha anualmente a estrutura e o desempenho das empresas comerciais do país. A série 2017–2023 permite comparar três cenários: pré-pandemia (2017–2019), pandemia (2020–2022) e retomada (2023). Os valores monetários estão em R\$ mil correntes (nominais, sem deflacionar).
Formato	Arquivo Excel (tabela1407.xlsx, cerca de 200 KB) com 6 abas: 5 de dados (uma por variável) e a aba Notas (legenda dos símbolos do IBGE). Em cada aba de dados, as linhas são as 23 categorias de atividade e as colunas cruzam 7 anos × 33 geografias (formato "largo").
Tamanho da base bruta	Após a reestruturação: 5.313 registros × 11 colunas = 23 categorias × 33 geografias (Brasil, 5 regiões, 27 UFs) × 7 anos.

Item	Descrição
Recorte usado	Por decisão do projeto, a análise exclui as regiões Norte e Nordeste (16 UFs). A base analisada tem 2.415 registros (15 geografias: Brasil, 3 regiões e 11 UFs), dos quais 1.134 trazem dados de fato (Seção 3.3).
Objetivo	Classificação supervisionada do desempenho das empresas comerciais em classes (queda / estável / crescimento) em cada cenário. A variável-alvo será derivada das variações percentuais dos indicadores e ainda não existe na base.
Unidade de análise	Um registro = uma combinação de categoria de atividade × geografia × ano.

Tabela 1 — Descrição da base de dados.

2.2 Atributos

A base reestruturada tem 11 colunas: 6 numéricas (o ano e 5 indicadores econômicos) e 5 categóricas, três delas derivadas durante o carregamento (período, nível geográfico e macrorregião).

Atributo	Tipo	Descrição / unidade
categoria	categórico nominal (23 níveis, hierárquico)	Divisão de comércio e grupo de atividade: 1. Total; 2. Veículos; 3. Atacado (3.1 a 3.8, com 3.5.1 e 3.5.2); 4. Varejo (4.1 a 4.7, com 4.1.1 e 4.1.2)
geografia	categórico nominal (33 níveis; 15 após o recorte)	Brasil, 5 grandes regiões e 27 unidades da federação
ano	numérico discreto (temporal)	2017 a 2023
unidades_locais	numérico discreto	Nº de unidades locais com receita de revenda (unidades)
peessoal_ocupado	numérico discreto	Pessoal ocupado em 31/12 (pessoas)
gastos_salarios	numérico contínuo	Salários, retiradas e outras remunerações (R\$ mil)
margem_comercializacao	numérico contínuo	Receita líquida de revenda menos o custo da mercadoria vendida (R\$ mil)
receita_bruta	numérico contínuo	Receita bruta de revenda de mercadorias (R\$ mil)
periodo	categórico ordinal (derivado)	Pré-pandemia < Pandemia < Retomada
nivel_geografico	categórico nominal (derivado)	Brasil / Região / UF
macrorregiao	categórico nominal (derivado)	Grande região a que a geografia pertence

Tabela 2 — Atributos da base reestruturada.

3. Preparação e verificação dos dados

3.1 Carregamento e reestruturação

A planilha original vem no formato "largo" do SIDRA: cada uma das 5 abas de dados corresponde a uma variável, com as categorias de atividade nas linhas e o cruzamento ano × geografia nas colunas. O primeiro passo do notebook transforma esse formato em uma tabela "tidy" — uma linha por combinação (categoria, geografia, ano), com as 5 variáveis como colunas. Nessa etapa os símbolos do IBGE são convertidos: o traço "-" (zero absoluto) vira 0 e os símbolos X, .. e ... (sigilo, não se aplica e não disponível) viram valores ausentes. Também são criadas as colunas derivadas *periodo*, *nivel_geografico* e *macrorregiao*. O resultado são 5.313 registros × 11 colunas.

3.2 Recorte geográfico

Por decisão do projeto, as regiões Norte e Nordeste (16 UFs) foram excluídas da análise. A base passou de 5.313 para 2.415 registros, cobrindo Brasil, as regiões Sudeste, Sul e Centro-Oeste e as 11 UFs dessas regiões (4 do Sudeste, 3 do Sul e 4 do Centro-Oeste). Uma ressalva importante: o detalhamento por subgrupo de atividade (categorias 3.x e 4.x) só existe em 6 UFs — Minas Gerais, Paraná, Rio de Janeiro, Rio Grande do Sul, Santa Catarina e São Paulo — e essa limitação não é exclusiva do Norte/Nordeste: Espírito Santo e as 4 UFs do Centro-Oeste permanecem sem esse detalhamento. Por isso, nesta sprint, as comparações por atividade usam apenas os 3 grandes grupos (veículos, atacado e varejo), disponíveis nas 11 UFs.

3.3 Verificação de qualidade e cobertura

Antes de produzir os gráficos, foi verificada a cobertura real da base. A tabela abaixo resume o que se encontrou ao inspecionar os valores zero (símbolo "-" do SIDRA):

Nível	Geografias	Registros (geografias × 23 categorias × 7 anos)	O que tem dado de fato
Brasil	1	161	Só a categoria "1. Total"; grupos e subgrupos aparecem como zero
Regiões	3	483	Só a categoria "1. Total" (Sudeste, Sul e Centro-Oeste)
UFs	11	1.771	Total e os 3 grandes grupos em todas; os 19 subgrupos 3.x e 4.x só em 6 UFs (MG, PR, RJ, RS, SC, SP)

Tabela 3 — Cobertura da base por nível geográfico, após o recorte.

No total, **1.281 dos 2.415 registros (53%)** têm as 5 variáveis iguais a zero ao mesmo tempo, e apenas **1.134** trazem dados de fato. Esses zeros não são zeros reais, e sim ausência de publicação do dado naquele nível de detalhe (por exemplo, Goiás tem o comércio atacadista preenchido, mas todos os seus subgrupos aparecem como zero). Duas consequências para esta sprint: (i) estatísticas calculadas sobre a base inteira ficam distorcidas pelos zeros; (ii) as análises por grupo de atividade usam o nível UF e os 3 grandes grupos, e Brasil e regiões só são usados para a categoria "1. Total". O tratamento formal desses registros (dados ausentes) é o primeiro item da Sprint 2.

4. Análise exploratória e descritiva

Salvo indicação em contrário, as análises desta seção usam o conjunto *uf_total*: as 11 UFs mantidas, categoria "1. Total", 7 anos (77 registros). É o recorte em que os 5 indicadores estão sempre preenchidos.

4.1 Estatísticas descritivas

Indicador	Mínimo	Mediana	Média	Máximo	Desvio padrão
Nº de unidades locais	18.478	88.370	116.588	492.201	119.085
Pessoal ocupado	134.178	520.302	735.045	3.064.523	782.636
Gastos com salários (R\$ mil)	2.938.233	13.317.777	20.618.878	125.809.719	26.323.367
Margem de comercialização (R\$ mil)	10.860.318	52.965.842	80.015.407	503.811.890	93.953.606
Receita bruta de revenda (R\$ mil)	57.522.655	281.445.461	397.708.497	2.249.633.684	431.638.789

Tabela 4 — Estatísticas descritivas dos 5 indicadores (11 UFs, categoria Total, 2017–2023). Valores monetários em R\$ mil.

A distância entre a mediana e o máximo em todos os indicadores já antecipa o que os histogramas mostram: um estado (São Paulo) concentra uma fatia muito maior da atividade comercial do que os demais, e a média é puxada para cima por ele.

4.2 Distribuição dos indicadores

Distribuição dos indicadores econômicos por UF (2017–2023, categoria Total)




Figura 1 — Distribuição dos 5 indicadores econômicos por UF (2017–2023, categoria Total).

Interpretação. As distribuições são fortemente assimétricas à direita — esperado, já que estados como São Paulo concentram uma quantidade de empresas, empregos e receita muito acima da média dos demais. Isso reforça que, na etapa de pré-processamento, provavelmente será necessário normalizar/padronizar essas variáveis (ou aplicar uma transformação logarítmica) antes de usá-las como atributos em algoritmos sensíveis à escala.

4.3 Variação anual por período (boxplots)

Em vez de olhar os níveis absolutos (que variam demais entre UFs), comparamos a **variação percentual ano a ano** de cada indicador — essa é a métrica que efetivamente captura o impacto da pandemia e será a base da futura variável de desempenho.

Variação percentual ano a ano por período, entre as 11 UFs




Figura 2 — Variação percentual ano a ano de cada indicador, por período, entre as 11 UFs. A linha tracejada marca variação zero.

Interpretação. A **receita bruta nominal** cresceu em praticamente todos os estados mesmo durante a pandemia (provavelmente reflexo da inflação e da migração para o comércio essencial e o e-commerce). Já o **número de unidades locais** e o **pessoal ocupado** caem claramente em 2020 e só voltam a crescer com força a partir de 2021 — esses dois indicadores parecem ser sinais muito mais fiéis do impacto real da pandemia sobre o setor do que a receita nominal isoladamente. A variável de desempenho (queda / estável / crescimento) talvez deva ser construída a partir de pessoal ocupado e/ou nº de unidades, não apenas da receita nominal.

4.4 Evolução temporal por macrorregião

Evolução por macrorregião (2017–2023)




Figura 3 — Evolução da receita bruta e do pessoal ocupado por macrorregião (2017–2023); a faixa cinza marca os anos de pandemia.

Interpretação. A região Sudeste domina em volume absoluto (esperado, dada sua participação no PIB nacional), mas o gráfico deixa visível a desaceleração/leve queda do pessoal ocupado em 2020 em todas as regiões, seguida de recuperação consistente a partir de 2021 — o mesmo padrão em formato de "V" aparece em todas elas, com intensidade um pouco diferente. A receita nominal, por sua vez, sobe de forma quase contínua.

4.5 Correlação entre os indicadores




Figura 4 — Matriz de correlação (Pearson) entre os 5 indicadores, nível UF.

Interpretação. Como esperado, todas as variáveis são fortemente correlacionadas entre si (todas medem, de formas diferentes, o tamanho da atividade comercial de um estado). Isso é um sinal de alerta para o pré-processamento: usar as 5 variáveis em nível absoluto como

atributos traria forte multicolinearidade. Pode ser mais interessante trabalhar com as variações percentuais ou com razões (receita por unidade local, receita por funcionário) em vez dos níveis brutos, e avaliar se PCA ou seleção de atributos se justifica.

4.6 Pessoal ocupado × receita bruta




Figura 5 — Dispersão entre pessoal ocupado e receita bruta por UF e ano, colorida por período. Eixos em escala logarítmica, com os valores reais nos rótulos.

Interpretação. A relação entre pessoal ocupado e receita é aproximadamente linear em escala logarítmica (estados maiores têm mais empregados e mais receita), e os pontos dos três períodos ficam bastante misturados, sem um deslocamento visual óbvio. Isso confirma que os efeitos da pandemia aparecem melhor na variação ao longo do tempo por estado (Figura 2) do que na relação estática entre as variáveis. A escala log foi necessária porque os estados diferem em várias ordens de grandeza; sem ela, os pontos se acumulariam perto da origem.

4.7 Comparação por grupo de atividade




Figura 6 — Variação percentual do pessoal ocupado por grande grupo de atividade e período (11 UFs).

Interpretação. Esse recorte é o mais interessante para a proposta: o **comércio de veículos** (mais sensível a bens duráveis e a cadeias de suprimento) é o grupo mais volátil — tem a maior dispersão na pandemia e o maior salto na retomada — enquanto **atacado** e **varejo** (que incluem itens essenciais) oscilam muito menos. Essa distinção deve aparecer com força na modelagem de classificação nas próximas sprints.

4.8 Ranking: UFs mais afetadas em 2020 e com maior recuperação em 2023

Usando o pessoal ocupado (indicador mais fiel ao impacto real, ver Seção 4.3) como referência:

UF	Macrorregião	Variação % do pessoal ocupado em 2020
Espírito Santo	Região Sudeste	-10,3%
Rio Grande do Sul	Região Sul	-7,7%
São Paulo	Região Sudeste	-6,8%
Rio de Janeiro	Região Sudeste	-5,0%
Minas Gerais	Região Sudeste	-3,9%

Tabela 5 — As 5 UFs com maior queda de pessoal ocupado em 2020.

UF	Macrorregião	Variação % do pessoal ocupado em 2023
Goiás	Região Centro-Oeste	+8,6%
Espírito Santo	Região Sudeste	+7,2%
Rio Grande do Sul	Região Sul	+5,6%
Mato Grosso do Sul	Região Centro-Oeste	+5,1%
Santa Catarina	Região Sul	+4,7%

Tabela 6 — As 5 UFs com maior crescimento de pessoal ocupado em 2023 (retomada).

Interpretação. As maiores quedas de 2020 se concentram no Sudeste e no Sul (Espírito Santo, Rio Grande do Sul e São Paulo lideram), enquanto a retomada de 2023 é puxada pelo Centro-Oeste (Goiás e Mato Grosso do Sul) e, de novo, pelo Espírito Santo — que, por ter caído mais, também recupera mais. Esse comportamento do ES (grande oscilação em anos seguidos) merece atenção na Sprint 2, ao definir a variável-alvo.

5. Síntese dos achados e próximos passos

5.1 Principais achados da Sprint 1

- **Escopo geográfico:** Norte e Nordeste (16 UFs) foram excluídos por decisão do projeto. A análise cobre Sudeste, Sul e Centro-Oeste (11 UFs), com Brasil e as 3 regiões como referência.
- **Cobertura dos dados:** Brasil e regiões só têm a categoria Total; nas 11 UFs, o Total e os 3 grandes grupos estão completos, mas os 19 subgrupos só têm dados em 6 UFs. Dos 2.415 registros do recorte, 1.281 (53%) são zeros estruturais e apenas 1.134 trazem dados de fato.
- **Receita nominal × impacto real:** a receita bruta cresceu em termos nominais mesmo em 2020; pessoal ocupado e unidades locais mostram queda real em 2020 com recuperação a partir de 2021, e são candidatos mais adequados para a variável de desempenho.
- **Heterogeneidade regional:** as 3 macrorregiões seguem o mesmo padrão em "V", com intensidades diferentes.
- **Multicolinearidade:** os 5 indicadores são fortemente correlacionados; razões ou variações percentuais tendem a ser atributos melhores do que os níveis absolutos.
- **Assimetria e escala:** os níveis são muito assimétricos (São Paulo domina) e a relação pessoal × receita só fica linear em escala log — será preciso transformar/padronizar antes da modelagem.
- **Grupos de atividade:** o comércio de veículos é o mais volátil; atacado e varejo são mais estáveis.

5.2 Próximos passos (Sprint 2 — pré-processamento)

- Tratar os zeros estruturais como dados ausentes (remover ou restringir o recorte) e verificar os símbolos do SIDRA (X, .., ...).
- Avaliar ruídos por consistência interna (UFs somam a região; veículos + atacado + varejo = Total; subgrupos somam o grupo) e outliers em três escalas (nível, variação percentual e razões).
- Definir formalmente a variável de desempenho (queda / estável / crescimento) e avaliar o balanceamento das classes (2020 deve concentrar as quedas).
- Escolher o nível de análise para evitar dupla contagem (Total = 2 + 3 + 4; grupo 3 = soma dos 3.x); uma opção é usar as 11 UFs × 3 grandes grupos.
- Considerar deflacionar os valores monetários (por exemplo, pelo IPCA), já que a comparação entre anos hoje é nominal.

6. Gestão do projeto

6.1 Quadro Kanban (Trello)

O acompanhamento das tarefas da Sprint 1 foi feito em um quadro Kanban no Trello, compartilhado com a professora. Cada atividade da Tabela 7 corresponde a um cartão do quadro, movido entre as colunas conforme o andamento até a conclusão da sprint.

6.2 Registro das atividades (16 a 30 de setembro de 2026)

Data	Atividade	Responsável
16/09	Reunião inicial da equipe; definição do tema e escolha da base (Tabela 1407 — PAC/IBGE); criação do quadro no Trello.	Equipe
17–18/09	Download da base no SIDRA; leitura da aba Notas (símbolos do IBGE); entendimento do formato largo (ano × geografia).	Equipe
19–22/09	Implementação do carregamento e da reestruturação em formato tidy; mapeamento UF → região; criação das variáveis derivadas (período, nível geográfico, macrorregião).	Equipe
23/09	Decisão do recorte geográfico (exclusão de Norte e Nordeste); verificação de qualidade e identificação dos zeros estruturais.	Equipe
24–26/09	Produção dos gráficos (distribuições, boxplots por período, evolução regional, correlação, dispersão, grupos de atividade) e redação das interpretações.	Equipe
27–28/09	Ranking das UFs (queda em 2020 e recuperação em 2023); revisão das interpretações; ajuste da legibilidade dos eixos em escala log.	Equipe
29/09	Organização do notebook Sprint1.ipynb e publicação no repositório do GitHub.	Equipe
30/09	Redação da primeira versão do relatório; atualização final do quadro Kanban.	Equipe

Tabela 7 — Registro das atividades da equipe na Sprint 1.

7. Seções reservadas para as próximas sprints

Conforme orientação do roteiro, as seções abaixo fazem parte da estrutura do relatório final, mas ficam reservadas para as etapas posteriores do projeto e não foram preenchidas nesta versão.

7.1 Pré-processamento dos dados (Sprint 2)

Reservado — dados ausentes, ruídos e outliers, transformação e seleção de atributos, definição da variável-alvo.

7.2 Modelagem (Sprint 3)

Reservado — escolha dos algoritmos de classificação, treinamento e ajuste de hiperparâmetros.

7.3 Avaliação e resultados (Sprint 4)

Reservado — métricas, comparação entre modelos e discussão dos resultados.

7.4 Conclusão

Reservado.

Referências

- IBGE — Instituto Brasileiro de Geografia e Estatística. *Pesquisa Anual de Comércio (PAC)*. Tabela 1407 — Dados gerais das empresas comerciais por grandes regiões e unidades da federação de atuação das empresas e divisão de comércio e grupo de atividade. SIDRA. Disponível em: <https://sidra.ibge.gov.br/Tabela/1407>.
- Repositório do projeto no GitHub (código da análise — Sprint1.ipynb): <https://github.com/NicolasSimoese/cienciasdedados>.
- Bibliotecas utilizadas: pandas, NumPy, Matplotlib, seaborn e openpyxl (Python 3).